# LAPORAN TUGAS 1 KECERDASAN KOMPUTASIONAL

# Implementasi Algoritma k-Nearest Neighbors (k-NN) Menggunakan Python dan Weka dengan Variasi k dan Variasi Fungsi Jarak



KELAS: C

5115100043 HAFARA FIRDAUSI

Dosen:

Dini Adni Navastara, S.Kom., M.Sc

Asisten:

M. ANWAR HIDAYAT

Jurusan Teknik Infomatika - Fakultas Teknologi Informasi Institut Teknologi Sepuluh Nopember (ITS) Surabaya 2017

#### **BABI**

#### **PENDAHULUAN**

#### 1.1 Latar Belakang

Machine Learning adalah pengambilan pengetahuan dari suatu data. Penerapan metode Machine Learning dalam beberapa tahun terakhir telah berkembang di mana-mana dalam kehidupan sehari-hari. Dari rekomendasi film, makanan apa yang harus dipesan atau produk mana yang akan dibeli, ke radio online yang telah dipersonalisasi dan mengenali teman di foto Anda, banyak situs web dan perangkat modern memiliki algoritma Machine Learning pada intinya. Ketika Anda melihat situs web yang kompleks seperti Facebook, Amazon, atau Netflix, kemungkinan besar setiap bagian situs berisi beberapa model Machine Learning.

Salah satu jenis Algoritma *Machine Learning* adalah Algoritma *Supervised Learning*, yaitu algoritma yang terdiri dari variabel dependen (data *train*) yang akan menjadi bahan prediksi dari himpunan prediktor (data *test*). Salah satu contoh Algoritma *Supervised Learning* yang paling populer adalah *k-Nearest Neighbor (k-NN)*. Oleh karena itu, kita sebagai anak informatika seharusnya mengerti bagaimana mengimplementasikan Algoritma *k-NN* dengan baik menggunakan Python dan Weka.

#### 1.2 Tujuan

- Dapat mengimplementasikan Algoritma *k*-NN dengan baik menggunakan Python dan Weka
- Dapat menganalisis dan menyimpulkan hasil uji coba dengan variasi *k* dan variasi fungsi jarak

#### 1.3 Detail Tugas

Implementasi k-NN menggunakan Python dan Weka

- 1. Menggunakan Data UCI Machine Learning: Pima Indian Diabetes Data Set dan Housing Data Set
- 2. Menggunakan fungsi jarak (*distance*): Euclidean Distance, Manhattan Distance, Cosine Similarity, dll
- 3. Nilai *k* dinamis/ bervariasi (bisa di*input*kan)
- 4. Menggunakan fungsi normalisasi
- 5. Menggunakan 10-Fold Cross Validation
- 6. Menghitung Akurasi untuk klasifikasi Pima Indians Diabetes Data Set
- 7. Menggunakan fungsi *k*-NN untuk regresi pada Boston Housing Data Set dan klasifikasi pada Pima Indian Diabetes Data Set

#### **BAB II**

#### **METODE**

#### 2.1 Waktu dan Tempat

Waktu pengerjaan tugas adalah 1 minggu dan disusul dengan demo tugas kepada asisten dosen. Tempat pengerjaan tugas adalah bebas.

#### 2.2 Kebutuhan (Requirements)

- Personal Computer/ Laptop
- Sistem Operasi Windows/ Linux (bebas)
- Bahasa Pemrograman Python beserta *environment*-nya Ada 5 *library* utama yang harus terinstall :
  - 1. Scipy
  - 2. Numpy
  - 3. Matplotlib
  - 4. Pandas
  - 5. Sklearn
- Software Weka 3: Data Mining Software in Java
- Data Set :
  - 1. Pima Indian Diabetes Data Set
  - 2. Boston Housing Data Set

#### 2.3 Prosedur Kerja


- 1. Meng-install Python environment ke dalam sistem operasi yang digunakan (saya menggunakan Linux Ubuntu 16.04), beserta 5 library yang harus terinstall
- 2. Meng-install Weka 3: Data Mining Software in Java (bisa di download dari web resminya, http://www.cs.waikato.ac.nz/ml/weka/)
- 3. Men-download Pima Indian Diabetes Data Set
  (https://archive.ics.uci.edu/ml/datasets/pima+indians+diabetes) dan Boston
  Housing Data Set (https://archive.ics.uci.edu/ml/machine-learningdatabases/housing/) di web resmi UCI Machine Learning Repository
  (https://archive.ics.uci.edu/ml/datasets.html)
- 4. Melakukan uji coba implementasi k-NN *algorithm* terhadap dataset menggunakan Python dan Weka dengan variasi *k* dan variasi fungsi jarak
- 5. Melakukan analisa terhadap hasil yang didapat

# BAB III DASAR TEORI

#### 3.1 *k-Nearest Neighbors* (*k*-NN)

#### 3.1.1 **Definisi** *k*-NN

**k-Nearest Neighbor (k-NN)** adalah sebuah metode untuk melakukan klasifikasi terhadap objek berdasarkan data *training* yang jaraknya paling dekat dengan objek tersebut. Data *training* diproyeksikan *k*-ruang berdimensi banyak, dimana masing-masing dimensi merepresentasikan fitur dari data. Tujuan dari algoritma ini adalah mengklasifikasikan objek baru berdasarkan atribut dan data *training*.



Dalam pengenalan pola, *k-Nearest Neighbor* (*k*-NN) adalah metode non-parametrik (model yang tidak mengasumsikan apa-apa mengenai distribusi instance di dalam dataset) yang digunakan untuk **klasifikasi** dan **regresi**. Dalam kedua kasus tersebut, *input* terdiri dari *k*-data *training* terdekat di ruang fitur. *Output*-nya bergantung pada apakah *k*-NN digunakan untuk klasifikasi atau regresi:

- Jika Klasifikasi k-NN, output-nya adalah class. Data test diklasifikasikan berdasarkan majority vote dari class tetangga terdekatnya (nearest neighbor) sejumlah k
- Jika **Regresi** *k***-NN**, output-nya adalah nilai properti, yaitu nilai rata-rata dari nilai tetangga terdekatnya (*nearest neighbor*) sejumlah *k*

#### Kelebihan dari k-NN yaitu:

- 1. Tangguh terhadap data training yang memiliki banyak noise
- 2. Efektif apabila data training-nya besar

#### Sedangkan, kelemahan dari k-NN adalah:

- 1. K-NN perlu menentukan nilai dari parameter k (jumlah dari tetangga terdekat)
- 2. *Training* berdasarkan jarak tidak jelas mengenai jenis jarak apa yang harus digunakan
- 3. Atribut mana yang harus digunakan untuk mendapatkan hasil yang terbaik
- 4. Biaya komputasi cukup tinggi karena diperlukan perhitungan jarak dari tiap data *test* pada keseluruhan data *training*

#### 3.1.2 Algoritma k-NN

Untuk setiap objek data test (X) dalam dataset:

- 1. Menghitung jarak antara X dengan setiap data training
- 2. Mengurutkan jarak dari yang paling kecil (kedekatan terbesar)
- 3. Mengambil k-data dengan jarak paling kecil dengan X
- 4. Mencari *majority vote* dari *class* diantara *k* data tersebut
- 5. Mengembalikan *majority vote* dari *class* tersebut sebagai prediksi class dari X

#### Cara memilih nilai k yang baik:

- 1. Jangan terlalu kecil, karena akan menghasilkan data noise
- 2. Jangan terlalu besar, karena tetangga (*neighborhood*) mungkin saja memasukkan data dari kelas lain

#### 3.1.3 Perhitungan Jarak dalam k-NN

Dalam percobaan implementasi ini, saya hanya menggunakan 3 macam Algoritma perhitungan jarak, yaitu:

#### 1. Euclidean Distance

Euclidean Distance membandingkan jarak minimum data test dengan data training. Euclidean Distance dihitung dengan persamaan:

$$dist = \sqrt{\sum_{k=1}^{n} (p_k - q_k)^2}$$

Semakin kecil nilai d(x,y), maka semakin mirip kedua data yang dibandingkan. Sebaliknya, semakin besar nilai d(x,y), maka semakin berbeda kedua data yang dibandingkan.

#### 2. Cosine Similarity

Cosine Similarity dihitung dengan persamaan:

$$cos(d_1, d_2) = (d_1 \cdot d_2) / ||d_1|| ||d_2||$$

#### 3. Manhattan Distance

Prosedur ini disebut blok absolut atau lebih dikenal dengan *city block distance. Manhattan Distance* dihitung dengan persamaan:

$$d(x, y) = L_p = i(x, y) = \sum_{i=1}^{n} ||x_i - y_i||$$

#### 3.1.4 Cara Implementasi Algoritma k-NN ke dalam Python

- 1. *Handle Data*: Membuka dataset dari CSV dan membaginya menjadi data *training* dan data *testing*
- 2. Similarity: Menghitung jarak antara 2 data
- 3. **Neighbors:** Menemukan *k* data yang paling mirip
- 4. Response: Mendapatkan hasil majority vote dari class dari tetangga
- 5. Accuracy: Meringkas ke akuratan prediksi
- 6. Main: Menggabungkan itu semua

Kita juga bisa menambahkan fungsi berikut dalam code:

- Regresi: Mengatasi masalah regresi (memprediksi atribut bernilai riil).
   Untuk mencari instances terdekat, dilakukan pengambilan rata-rata dari atribut yang di prediksi.
- Normalisasi: Mengatasi masalah perbedaan satuan ukuran antar atribut, yang menyebabkan suatu atribut sangat mendominasi atribut yang lain dalam hal kontribusi penghitungan jarak. Misal: Atribut A = 5 kg, Atribut B = Rp10.000, terlihat sangat tampak kesenjangan nilai antar 2 atribut (satuan dan puluh ribuan). Hal ini tentunya harus dinormalisasi karena kisaran range variabel yang besar akan menjadi bias. Caranya adalah dengan me-rescale semu data atribut dalam range 0-1.

$$x' = rac{x - \min(x)}{\max(x) - \min(x)}$$

 Ukuran Jarak Alternatif: Ada banyak persamaan lain untuk menghitung jarak, seperti Manhattan Distance dan Cosine Similarity.

#### **BAB IV**

#### HASIL IMPLEMENTASI

#### 4.1 Pima Indians Diabetes Data Set

Abstract: From National Institute of Diabetes and Digestive and Kidney Diseases; Includes cost data (donated by Peter Turney)

Data Set Characteristics:	Multivariate	Number of Instances:	768	Area:	Life
Attribute Characteristics:	Integer, Real	Number of Attributes:	8	Date Donated	1990-05-09
Associated Tasks:	Classification	Missing Values?	Yes	Number of Web Hits:	314438

#### 4.1.1 Python

- Source Code
  - 1. Import Library

```
### IMPORT LIBRARY ###
import csv
import random
import math
import operator
```

**2.** *Handle Data:* Membuka dataset dari CSV dan membaginya menjadi data *training* dan data *testing*. Tambahkan pula fungsi yang meng*handle missing value* dan fungsi normalisasi

```
### HANDLE DATA ###
def loadDataset (filename, split, trainingSet=[], testSet=[]):
    with open(filename, 'rb') as csvfile:
        lines = csv.reader(csvfile)
                  dataset = list(lines)
                  flag = 0
         # Handle missing value
         for x in range(len(dataset)):
                  for y in range (len (dataset[x]) - 1):
                           if float (dataset[x][y]) == 0.0:
                                    kolom = [float (i[y]) for i in dataset]
                                    tidakNol = len(kolom) - kolom.count (0)
                                   dataset[x][y] = float(sum(kolom)/tidakNol)
                           else:
                                   dataset[x][y] = float(dataset[x][y])
         # Fungsi Normalisasi
         for x in range(len(dataset)):
                  minx = min([i for i in dataset[x][:-1]])
                  maxx = max([i for i in dataset[x][:-1]])
                  for y in range (len (dataset[x]) - 1):
                          dataset[x][y] = (dataset[x][y] - minx) / (maxx - minx)
         # Membagi data training dan data testing
         for x in range(len(dataset)-1):
                  for y in range(4):
                          dataset[x][y] = float (dataset[x][y])
                  if flag < split * len(dataset):</pre>
                           trainingSet.append (dataset[x])
                           flag += 1
                  else:
                           testSet.append (dataset[x])
```

3. Similarity: Menghitung jarak antara 2 data. Saya menggunakan 3 variasi

fungsi jarak

```
### SIMILARITY ###
#EUCLIDEAN DIST
def euclideanDistance(instance1, instance2, length):
        distance = 0
        for x in range(length):
                 distance += float(pow((float(instance1[x]) - float(instance2
[x])), 2))
        return float(math.sqrt(distance))
#MANHATTAN DIST
def manhattanDistance(instance1, instance2, length):
        distance = 0
        for x in range(length):
                 temp = instance1[x] - instance2[x]
        if temp < 0:</pre>
                 temp*=-1
        distance += temp
        return math.sqrt(distance)
#COSINE SIMILARITY
def cosineSimilarity(instance1, instance2, length):
        distance = 0
        sumxx, sumxy, sumyy = 0, 0, 0
for i in range(length):
                x = float(instance1[i])
                 y = float(instance2[i])
                 SUMXX += X * X
                 sumyy += y * y
                 sumxy += x * y
        return 1 - (sumxy / math.sqrt(sumxx * sumyy))
```

**4. Neighbors:** Menemukan *k* data yang paling mirip

```
### K NEIGHBORS ###
def getNeighbors(trainingSet, testInstance, k, pilih):
        distances = []
        length = len(testInstance) - 1
        for x in range(len(trainingSet)):
                if pilih==1:
                        dist = euclideanDistance(testInstance,trainingSet[x],length)
                elif pilih==2:
                        dist = manhattanDistance(testInstance,trainingSet[x],length)
                elif pilih==3:
                        dist = cosineSimilarity(testInstance,trainingSet[x],length)
                distances.append((trainingSet[x], dist))
        distances.sort(key=operator.itemgetter(1))
        neighbors = []
        for x in range(k):
                neighbors.append(distances[x][0])
        return neighbors
```

5. Response: Mendapatkan hasil majority vote dari class dari tetangga

```
### RESPONSE -- MAJORITY VOTE OF CLASS ###
def getResponse(neighbors):
    classVotes = {}
    for x in range(len(neighbors)):
        response = neighbors[x][-1]
    if response in classVotes:
        classVotes[response] += 1
    else:
        classVotes[response] = 1
    sortedVotes = sorted(classVotes.items(),key=operator.itemgetter(1), reverse=True)
    return sortedVotes[0][0]
```

6. Accuracy: Meringkas keakuratan prediksi

7. Main: Menggabungkan semua fungsi

```
### MAIN ###
def main():
          # prepare data
trainingSet = []
          testSet = []
          split = 0.8
          loadDataset('pima-indians-diabetes.data', split, trainingSet, testSet)
print('\nData Train: ' + repr(len(trainingSet)))
print('Data Test: ' + repr(len(testSet)))
          # generate predictions
          predictions = []
k = input("\nMasukkan nilai k : ")
print "\n1. Euclidean Distance\n2. Manhattan Distance\n3. Cosine Similarity\n"
          pilih = input("Masukkan pilihan fungsi jarak yang ingin digunakan : ")
for x in range(len(testSet)):
                     neighbors = getNeighbors(trainingSet, testSet[x], k, pilih)
                     result = getResponse(neighbors)
                     predictions.append(result)
                    print('> Predicted=' + repr(result) + ', Actual=' + repr(testSet[x][-1]))
          accuracy = getAccuracy(testSet, predictions)
          print('Accuracy: ' + repr(accuracy) + '%')
main()
```

#### Testing

K = 3, Menggunakan fungsi jarak Euclidean Distance

```
root@hf-VirtualBox:/home/hf/Downloads/kk/tugas# python knn-klasifikasi.py
Data Train: 615
Data Test: 152
Masukkan nilai k : 3
1. Euclidean Distance
Manhattan Distance
Cosine Similarity
Masukkan pilihan fungsi jarak yang ingin digunakan : 1
> Predicted='1', Actual='0'
> Predicted='0', Actual='0'
> Predicted='0', Actual='0'
> Predicted='1', Actual='1'
> Predicted='1', Actual='1'
> Predicted='0', Actual='0'
> Predicted='0', Actual='1'
> Predicted='0', Actual='0'
> Predicted='1', Actual='1'
> Predicted='1', Actual='1'
> Predicted='1', Actual='0'
> Predicted='1', Actual='0'
> Predicted='1', Actual '0'
> Predicted='1', Actual='1'
> Predicted='1', Actual='0'
> Predicted='0', Actual='0'
> Predicted='0'
> Predicted='0', Actual='1'
> Predicted='0', Actual='0'
> Predicted='0', Actual='1'
  Predicted='1', Actual='1'
Predicted='1', Actual
> Predicted='1'
  Predicted='1', Actual='1'
Predicted='1', Actual
> Predicted='1', Actual='0'
> Predicted='1', Actual='0'
> Predicted='0', Actual='1'
> Predicted='1', Actual='1'
> Predicted='0', Actual='1'
> Predicted='0', Actual='0'
> Predicted='1', Actual='1'
> Predicted='1', Actual='1'
> Predicted='0', Actual='0'
> Predicted='1', Actual='1'
> Predicted '0'
> Predicted='0', Actual='0'
> Predicted='1', Actual='1'
> Predicted='1', Actual='0'
> Predicted= 1 , Actual= 0
> Predicted='0', Actual='0'
> Predicted='1', Actual='0'
> Predicted='1', Actual='1'
Accuracy: 62.5%
```

#### Hasil


Total Data: 768

Data *Train*: 615 (80% total data) Data *Test*: 152 (20% total data)


		Akurasi								
	k = 3	<i>k</i> = 5	k = 7	<i>k</i> = 9	K = 11					
Euclidean Dist.	62.5%	68.4210%	61.1842%	63.8157%	65.7895%					
Manhattan Dist.	52.6316%	56.5789%	56.5789%	58.5526%	50.6579%					
Cosine Similarity	66.4473%	59.2105%	59.2105%	64.4737%	62.5%					

#### 4.1.2 Weka

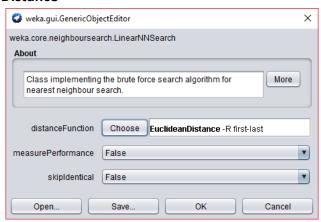
1. Buka Weka Explorer dan masukkan data pima-indians-diabetes.arff (https://raw.githubusercontent.com/lpfgarcia/ucipp/master/uci/pima-indians-diabetes.arff) ke dalam Weka melalui Open File



- 2. Atur sedemikian rupa seperti ini:
  - a) 10-Cross Validation



- 3. Klasifikasi menggunakan k-NN/IBK dengan 2 variasi fungsi jarak
  - Euclidean Distance



#### a) k = 3

```
=== Stratified cross-validation ===
=== Summary ===
                                                            72.6563 %
Correctly Classified Instances
                                        558
                                       210
Incorrectly Classified Instances
                                                           27.3438 %
                                          0.3822
Kappa statistic
Mean absolute error
                                          0.3092
Root mean squared error
                                          0.4525
                                        68.0324 %
94.9365 %
Relative absolute error
Root relative squared error
Total Number of Instances
                                        768
=== Detailed Accuracy By Class ===
                 TP Rate FP Rate Precision Recall F-Measure MCC
                                                                              ROC Area PRC Area Class
                                            0.820 0.796 0.384 0.742 0.804
0.552 0.585 0.384 0.742 0.569
0.727 0.722 0.384 0.742 0.722
                          0.448 0.774 0.820
0.180 0.622 0.552
                 0.820
                 0.552
                                                                                                    2
                          0.354 0.721
Weighted Avg.
                 0.727
=== Confusion Matrix ===
  a b <-- classified as
410 90 | a = 1
120 148 | b = 2
```

#### b) k = 5

```
=== Stratified cross-validation ===
=== Summary ===
```

Correctly Classified Instances	562	73.1771
Incorrectly Classified Instances	206	26.8229
Kappa statistic	0.3874	
Mean absolute error	0.3165	
Root mean squared error	0.4318	
Relative absolute error	69.6387 %	
Root relative squared error	90.5982 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.836	0.463	0.771	0.836	0.802	0.390	0.766	0.828	1
	0.537	0.164	0.637	0.537	0.583	0.390	0.766	0.619	2
Weighted Avg.	0.732	0.358	0.724	0.732	0.726	0.390	0.766	0.755	

=== Confusion Matrix ===

a b <-- classified as 418 82 | a = 1 124 144 | b = 2

#### c) k = 7

=== Stratified cross-validation === === Summary ===

Correctly Classified Instances	574	74.7396 %
Incorrectly Classified Instances	194	25.2604 %
Kappa statistic	0.4189	
Mean absolute error	0.3178	
Root mean squared error	0.4209	
Relative absolute error	69.9184 %	
Root relative squared error	88.3093 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.856	0.455	0.778	0.856	0.815	0.424	0.785	0.853	1
	0.545	0.144	0.670	0.545	0.601	0.424	0.785	0.643	2
Weighted Avg.	0.747	0.347	0.740	0.747	0.740	0.424	0.785	0.780	

=== Confusion Matrix ===

a b <-- classified as  $428 \ 72 \ | \ a = 1 \ 122 \ 146 \ | \ b = 2$ 

#### d) k = 9

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	554	72.1354 %
Incorrectly Classified Instances	214	27.8646 %
Kappa statistic	0.3602	
Mean absolute error	0.3221	
Root mean squared error	0.4187	
Relative absolute error	70.8694 %	
Root relative squared error	87.8344 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.834	0.489	0.761	0.834	0.796	0.364	0.790	0.859	1
	0.511	0.166	0.623	0.511	0.561	0.364	0.790	0.643	2
Weighted Avg.	0.721	0.376	0.713	0.721	0.714	0.364	0.790	0.783	

=== Confusion Matrix ===

a b <-- classified as  $417 \ 83 \ | \ a = 1 \ 131 \ 137 \ | \ b = 2$ 

#### e) k = 11

```
=== Stratified cross-validation ===
=== Summary ===
```

Correctly Classified Instances	550	71.6146 %
Incorrectly Classified Instances	218	28.3854 %
Kappa statistic	0.3446	
Mean absolute error	0.3254	
Root mean squared error	0.4167	
Relative absolute error	71.6048 %	
Root relative squared error	87.4307 %	
Total Number of Instances	768	


=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.836	0.507	0.755	0.836	0.793	0.349	0.794	0.866	1
	0.493	0.164	0.617	0.493	0.548	0.349	0.794	0.650	2
Weighted Avg.	0.716	0.388	0.706	0.716	0.708	0.349	0.794	0.791	

=== Confusion Matrix ===

a b <-- classified as 418 82 | a = 1 136 132 | b = 2

#### Manhattan Distance



#### a) k = 3

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	545	70.9635 %
Incorrectly Classified Instances	223	29.0365 %
Kappa statistic	0.3351	
Mean absolute error	0.3209	
Root mean squared error	0.4646	
Relative absolute error	70.6083 %	
Root relative squared error	97.4825 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.822	0.500	0.754	0.822	0.787	0.338	0.723	0.790	1
	0.500	0.178	0.601	0.500	0.546	0.338	0.723	0.554	2
Weighted Avg.	0.710	0.388	0.701	0.710	0.703	0.338	0.723	0.707	

=== Confusion Matrix ===

#### b) k = 5

=== Stratified cross-validation === === Summary ===

Correctly Classified Instances	556	72.3958 %
Incorrectly Classified Instances	212	27.6042 %
Kappa statistic	0.365	
Mean absolute error	0.3194	
Root mean squared error	0.4374	
Relative absolute error	70.2686 %	
Root relative squared error	91.7663 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.838	0.489	0.762	0.838	0.798	0.369	0.755	0.821	1
	0.511	0.162	0.628	0.511	0.564	0.369	0.755	0.604	2
Weighted Avg.	0.724	0.375	0.715	0.724	0.716	0.369	0.755	0.745	

=== Confusion Matrix ===

a b <-- classified as 419 81 | a = 1 131 137 | b = 2

#### c) k = 7

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	558	72.6563	ê
Incorrectly Classified Instances	210	27.3438	olo
Kappa statistic	0.3675		
Mean absolute error	0.3278		
Root mean squared error	0.4305		
Relative absolute error	72.1275 %		
Root relative squared error	90.3125 %		
Total Number of Instances	768		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.846	0.496	0.761	0.846	0.801	0.373	0.769	0.842	1
	0.504	0.154	0.637	0.504	0.563	0.373	0.769	0.603	2
Weighted Avg.	0.727	0.377	0.718	0.727	0.718	0.373	0.769	0.758	

=== Confusion Matrix ===

a b <-- classified as  $423 \ 77 \ | \ a = 1 \ 133 \ 135 \ | \ b = 2$ 

#### d) k = 9

=== Stratified cross-validation === === Summary ===

554	72.1354 %
214	27.8646 %
0.3496	
0.3308	
0.4275	
72.7786 %	
89.6991 %	
768	
	214 0.3496 0.3308 0.4275 72.7786 % 89.6991 %

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.852	0.522	0.753	0.852	0.799	0.357	0.776	0.852	1
	0.478	0.148	0.634	0.478	0.545	0.357	0.776	0.607	2
Weighted Avg.	0.721	0.392	0.711	0.721	0.710	0.357	0.776	0.767	

=== Confusion Matrix ===

a b <-- classified as 426 74 | a = 1 140 128 | b = 2

#### e) k = 11

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances	557	72.526	of o
Incorrectly Classified Instances	211	27.474	96
Kappa statistic	0.3628		
Mean absolute error	0.3275		
Root mean squared error	0.4199		
Relative absolute error	72.0474 %		
Root relative squared error	88.0862 %		
Total Number of Instances	768		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.848	0.504	0.758	0.848	0.801	0.369	0.787	0.858	1
	0.496	0.152	0.636	0.496	0.558	0.369	0.787	0.637	2
Weighted Avg.	0.725	0.381	0.716	0.725	0.716	0.369	0.787	0.781	

=== Confusion Matrix ===

a b <-- classified as  $424 \quad 76 \mid \quad a=1 \\ 135 \quad 133 \mid \quad b=2$ 

#### 4.2 Boston Housing Data Set

Concerns housing values in suburbs of Boston Number of Instances: 506

#### 4.2.1 Python

#### Source Code

#### 1. Import Library

### IMPORT LIBRARY ###
import csv
import random
import math
import operator
import numpy

**2.** *Handle Data:* Membuka dataset dari CSV dan membaginya menjadi data *training* dan data *testing*. Tambahkan pula fungsi yang meng*handle missing value* dan fungsi normalisasi

```
### HANDLE DATA ###
def loadDataset (filename, split, trainingSet=[], testSet=[]):
    with open(filename, 'rb') as csvfile:
                  lines = csv.reader(csvfile, delimiter = ' ', skipinitialspace = True)
                  dataset = list(lines)
                  flag = 0
         # Handle missing value
         for x in range(len(dataset)):
                  for y in range (len (dataset[x]) - 1):
                           if float (dataset[x][y]) == 0.0:
                                    kolom = [float (i[y]) for i in dataset]
                                     tidakNol = len(kolom) - kolom.count (0)
                                    dataset[x][y] = float(sum(kolom)/tidakNol)
                           else:
                                    dataset[x][y] = float(dataset[x][y])
         # Fungsi Normalisasi
         for x in range(len(dataset)):
                  minx = min([i for i in dataset[x][:-1]])
maxx = max([i for i in dataset[x][:-1]])
                  for y in range (len (dataset[x]) - 1):
                           dataset[x][y] = (dataset[x][y] - minx) / (maxx - minx)
         # Membagi data training dan data testing
         for x in range(len(dataset)-1):
                  for y in range(4):
                  dataset[x][y] = float (dataset[x][y])
if flag < split * len(dataset):</pre>
                           trainingSet.append (dataset[x])
                           flag += 1
                  else:
                           testSet.append (dataset[x])
```

**3.** *Similarity:* Menghitung jarak antara 2 data. Saya menggunakan 3 variasi

```
fungsi jarak
```

```
### SIMILARITY ###
#EUCLIDEAN DIST
def euclideanDistance(instance1, instance2, length):
        distance = 0
        for x in range(length):
                distance += float(pow((float(instance1[x]) - float(instance2
[x])), 2))
        return float(math.sqrt(distance))
#MANHATTAN DIST
def manhattanDistance(instance1, instance2, length):
        distance = 0
        for x in range(length):
                temp = instance1[x] - instance2[x]
        if temp < 0:</pre>
                temp*=-1
        distance += temp
        return math.sqrt(distance)
#COSINE SIMILARITY
def cosineSimilarity(instance1, instance2, length):
        distance = 0
        sumxx, sumxy, sumyy = 0, 0, 0
        for i in range(length):
                x = float(instance1[i])
                y = float(instance2[i])
                sumxx += x * x
                sumyy += y * y
                sumxy += x * y
        return 1 - (sumxy / math.sqrt(sumxx * sumyy))
```

**4. Neighbors:** Menemukan *k* data yang paling mirip

```
### K NEIGHBORS ###
def getNeighbors(trainingSet, testInstance, k, pilih):
        distances = []
        length = len(testInstance) - 1
        for x in range(len(trainingSet)):
                if pilih==1:
                        dist = euclideanDistance(testInstance,trainingSet[x],length)
                elif pilih==2:
                        dist = manhattanDistance(testInstance,trainingSet[x],length)
                elif pilih==3:
                        dist = cosineSimilarity(testInstance,trainingSet[x],length)
                distances.append((trainingSet[x], dist))
        distances.sort(key=operator.itemgetter(1))
        neighbors = []
        for x in range(k):
                neighbors.append(distances[x][0])
        return neighbors
```

5. Response: Mendapatkan hasil majority vote dari class dari tetangga

```
### RESPONSE -- MAJORITY VOTE OF CLASS ###
def getResponse(neighbors):
    classVotes = {}
    for x in range(len(neighbors)):
        response = neighbors[x][-1]
    if response in classVotes:
        classVotes[response] += 1
    else:
        classVotes[response] = 1
    sortedVotes = sorted(classVotes.items(),key=operator.itemgetter(1), reverse=True)
    return sortedVotes[0][0]
```


6. Accuracy: Meringkas keakuratan prediksi

#### 7. Main: Menggabungkan semua fungsi


```
### MAIN ###
def main():
             # prepare data
             trainingSet = []
             testSet = []
split = 0.8
total_regresi = 0
             loadDataset('housing.data', split, trainingSet, testSet)
print('\nData Train: ' + repr(len(trainingSet)))
print('Data Test: ' + repr(len(testSet)))
             # generate predictions
             predictions = []
             print "\nMasukkan nil
k = int(raw_input())
             print "\n1. Euclidean Distance\n2. Manhattan Distance\n3. Cosine Similarity\n"
print "\nMasukkan pilihan algoritma yang ingin digunakan : "
             typeDist = [euclideanDistance, manhattanDistance, cosineSimilarity][int(raw_input())]
             for x in range(len(testSet)):
                          regine(testset);
neighbors = getNeighbors(trainingSet, testSet[x], k, typeDist)
regresiBukan = sum ([n[-1] for n in neighbors]) / k
regresi = sum ([typeDist(testSet[x], n, len(testSet[x])) for n in neighbors]) / k
total_regresi += regresi
result = getResponse(neighbors)
predictions append(result)
                          predictions.append(result)
                          print('> Predicted=
for n in neighbors:
                                                             + repr(result) + ', Actual=' + repr(testSet[x][-1]))
                          print (n[-1])
print ('Regresi bukan rumus : ' + str(regresiBukan))
             accuracy = getAccuracy(testSet, predictions)
             #print('Accuracy: ' + repr(accuracy) + '%')
print('Regresi : ' + str(total_regresi/len(testSet)))
main()
```

#### 4.2.2 Weka


1. Buka Weka Explorer dan masukkan data pima-indians-diabetes.arff (http://tunedit.org/repo/UCI/numeric/housing.arff) ke dalam Weka melalui Open File




2. Handle MissingValue



- 3. Atur sedemikian rupa seperti ini:
  - b) 10-Cross Validation



- 4. Klasifikasi menggunakan k-NN/IBK dengan 2 variasi fungsi jarak
  - Euclidean Distance



#### a) k = 3

=== Classifier model (full training set) ===

IB1 instance-based classifier using 3 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.871
Mean absolute error	2.9544
Root mean squared error	4.5644
Relative absolute error	44.3116 %
Root relative squared error	49.5106 %
Total Number of Instances	506

#### b) k = 5

=== Classifier model (full training set) ===

IB1 instance-based classifier using 5 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.8591
Mean absolute error	2.9811
Root mean squared error	4.8173
Relative absolute error	44.7119 %
Root relative squared error	52.2536 %
Total Number of Instances	506

#### c) k = 7

=== Classifier model (full training set) ===

IB1 instance-based classifier using 7 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.8448
Mean absolute error	3.1655
Root mean squared error	5.039
Relative absolute error	47.4771 %
Root relative squared error	54.6591 %
Total Number of Instances	506

# d) k = 9

=== Classifier model (full training set) === IB1 instance-based classifier using 9 nearest neighbour(s) for classification Time taken to build model: 0 seconds === Cross-validation === === Summary === Correlation coefficient 0.8264 3.3603 Mean absolute error Root mean squared error 5.3075 50.3989 % Relative absolute error Root relative squared error 57.5713 % Total Number of Instances 506

#### e) k = 11

=== Classifier model (full training set) ===


IBl instance-based classifier
using ll nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation === === Summary ===

Correlation coefficient 0.8181
Mean absolute error 3.4018
Root mean squared error 5.4424
Relative absolute error 51.0221 %
Root relative squared error 59.0338 %
Total Number of Instances 506

#### • Manhattan Distance



#### a) k = 3=== Classifier model (full training set) === IB1 instance-based classifier using 3 nearest neighbour(s) for classification Time taken to build model: 0 seconds === Cross-validation === === Summary === Correlation coefficient 0.8931 2.7304 Mean absolute error Root mean squared error Relative absolute error Root relative squared error Total Number of Instances 4.1612 40.9522 % 45.1373 % 506 b) k = 5=== Classifier model (full training set) === IB1 instance-based classifier using 5 nearest neighbour(s) for classification Time taken to build model: 0 seconds === Cross-validation === === Summary === 0.8807 Correlation coefficient 2.8708 Mean absolute error Root mean squared error Relative absolute error 4.4186 43.0579 % Root relative squared error 47.9289 % 506 Total Number of Instances c) k = 7=== Classifier model (full training set) === IB1 instance-based classifier using 7 nearest neighbour(s) for classification Time taken to build model: 0 seconds === Cross-validation === === Summary === Correlation coefficient 0.8714

Mean absolute error

Total Number of Instances

Root mean squared error
Relative absolute error
Root relative squared error
Total Number of Instances

2.9727

4.6084 44.5858 % 49.9877 %

506

#### d) k = 9

=== Classifier model (full training set) ===

IB1 instance-based classifier using 9 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.8533
Mean absolute error	3.1184
Root mean squared error	4.909
Relative absolute error	46.7708 %
Root relative squared error	53.2487 %
Total Number of Instances	506

#### e) k = 11

=== Classifier model (full training set) ===

IB1 instance-based classifier using 11 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.8482
Mean absolute error	3.1725
Root mean squared error	5.0096
Relative absolute error	47.5824 %
Root relative squared error	54.3397 %
Total Number of Instances	506

# BAB V ANALISA DATA

#### 5.1 Pima Indians Diabetes Data Set

#### Hasil Python

Total Data: 768

Data *Train*: 615 (80% total data) Data *Test*: 152 (20% total data)

	Akurasi					
	k = 3	<i>k</i> = 5	k = 7	k = 9	K = 11	
Euclidean Dist.	62.5%	68.4210%	61.1842%	63.8157%	65.7895%	
Manhattan Dist.	52.6316%	56.5789%	56.5789%	58.5526%	50.6579%	
Cosine Similarity	66.4473%	59.2105%	59.2105%	64.4737%	62.5%	

Dari hasil pengumpulan data diatas, dapat kita analisa bahwa:

- a) Rata-rata tingkat akurasi klasifikasi tertinggi adalah Euclidean Distance
- b) Rata-rata tingkat akurasi klasifikasi terendah adalah Manhattan Distance
- c) Tingkat akurasi tertinggi pada Euclidean Distance adalah 68.4210% dengan k=5
- d) Tingkat akurasi tertinggi pada Manhattan Distance adalah 58.5526% dengan k=9
- e) Tingkat akurasi tertinggi pada Cosine Similarity adalah 66.4473% dengan k=3

# BAB VI PENUTUP

#### 5.1 Kesimpulan

Setelah kita melakukan uji coba dan analisa, dapat kita tarik kesimpulan bahwa:

- Nilai *k* tidak boleh terlalu besar maupun terlalu kecil. Semakin besar *k*, klasifikasi data cenderung semakin tidak akurat
- Euclidean Distance adalah metode perhitungan jarak yang lebih akurat (dibuktikan dengan rata-rata tingkat akurasi tertinggi) dibandingkan metode perhitungan jarak yang lain

#### **DAFTAR PUSTAKA**

- https://archive.ics.uci.edu/ml/datasets.html
- https://machinelearningmastery.com/tutorial-to-implement-k-nearest-neighbors-in-python-from-scratch/
- http://omahti.web.id/blog/langkah-pertama-belajar-machine-learning-menggunakan-python-part-1/
- https://mragungsetiaji.wordpress.com/2016/06/23/machine-learning-knn-k-nearest-neighbors-menggunakan-python/
- https://tentangdata.wordpress.com/2015/09/16/knn-perhitungan-jarakserta-keunggulan-dan-batasan/
- https://en.wikipedia.org/wiki/K-nearest\_neighbors\_algorithm